Airflow ML Pipeline: Cuckoo Search ile Churn Feature Selection

Müşteri kaybı tahmini için Airflow tabanlı uçtan uca makine öğrenmesi pipeline projesi

Proje Özeti: Müşteri kaybı tahmini için Airflow tabanlı uçtan uca bir makine öğrenmesi pipeline'ı geliştirildi. Random Forest modeli ile churn tahmini yapıldı ve Guguk Kuşu Algoritması kullanılarak feature selection uygulandı. Optimize modelde feature sayısı 30'dan 12'ye düşürülürken F1-score değeri 0.553'ten 0.589'a, recall değeri ise 0.492'den 0.684'e yükseltildi.

English Summary: Developed an Airflow-based machine learning pipeline for customer churn prediction using Random Forest classification and Cuckoo Search optimization for feature selection. The optimized model reduced the number of features from 30 to 12 while improving F1-score from 0.553 to 0.589 and recall from 0.492 to 0.684.

1. Projenin Amacı

Bu projenin amacı, müşteri kaybı yani **churn** riskini tahmin eden uçtan uca bir makine öğrenmesi pipeline'ı geliştirmektir. Proje aynı zamanda yüksek lisans kapsamında işlenen optimizasyon teknikleri ile gerçek bir veri bilimi problemini birleştirmektedir.

Projede Guguk Kuşu Algoritması doğrudan tahmin modeli olarak değil, **feature selection** amacıyla kullanılmıştır. Böylece modelin daha az değişkenle daha iyi performans üretip üretmediği test edilmiştir.

2. Kullanılan Teknolojiler

Alan	Kullanılan Teknoloji
Workflow orchestration	Apache Airflow
Programlama dili	Python
Veri işleme	Pandas, NumPy
Makine öğrenmesi	Scikit-learn
Model	Random Forest Classifier
Optimizasyon	Cuckoo Search / Guguk Kuşu Algoritması

Çıktı formatları	CSV, PKL model dosyası
Çalışma ortamı	Docker üzerinde Airflow

3. Veri Seti

Projede **Telco Customer Churn** veri seti kullanılmıştır. Veri seti telekom müşterilerinin abonelik bilgileri, hizmet kullanımları, ödeme bilgileri ve churn durumlarını içermektedir.

Örnek Kolonlar

- `gender`
- `SeniorCitizen`
- `Partner`
- `Dependents`
- `tenure`
- `InternetService`
- `Contract`
- `PaymentMethod`
- `MonthlyCharges`
- `TotalCharges`
- `Churn`

4. Airflow DAG Yapısı

Airflow DAG manuel tetiklenecek şekilde tasarlanmıştır. Kullanılan veri seti sabit olduğu için günlük schedule gerekli değildir. Ancak yapı, gerçek üretim ortamında yeni veri geldikçe günlük, haftalık veya aylık çalışacak şekilde kolayca genişletilebilir.

```
check_dataset_exists
        ↓
validate_columns
        ↓
clean_churn_data
        ↓
train_baseline_model
        ↓
cuckoo_search_feature_selection
        ↓
train_optimized_model
        ↓
generate_churn_predictions
```

5. Pipeline Adımları

5.1 Dataset Kontrolü

`check_dataset_exists` task'ı, ham veri dosyasının doğru klasörde olup olmadığını kontrol eder. Dosya yoksa pipeline hata verir.

5.2 Kolon Validasyonu

`validate_columns` task'ı, veri setinde beklenen kolonların bulunup bulunmadığını kontrol eder. Eksik kolon varsa işlem durdurulur.

5.3 Veri Temizleme ve Encoding

`clean_churn_data` task'ında aşağıdaki işlemler yapılmıştır:

- `customerID` kolonu model için anlamlı olmadığı için çıkarılmıştır.
- `TotalCharges` kolonu sayısal formata dönüştürülmüştür.
- Eksik değer içeren kayıtlar temizlenmiştir.
- `Churn` hedef değişkeni `Yes=1`, `No=0` olacak şekilde dönüştürülmüştür.
- Kategorik değişkenler one-hot encoding yöntemiyle sayısal hale getirilmiştir.

5.4 Baseline Model Eğitimi

`train_baseline_model` task'ında tüm feature'lar kullanılarak Random Forest modeli eğitilmiştir. Bu model, Cuckoo Search sonrası optimize modelle karşılaştırma yapmak için başlangıç noktasıdır.

5.5 Cuckoo Search ile Feature Selection

`cuckoo_search_feature_selection` task'ında Guguk Kuşu Algoritması kullanılarak en iyi feature alt kümesi aranmıştır. Her çözüm bir feature seçim kombinasyonu olarak temsil edilmiştir:

```
[1, 0, 1, 1, 0, 1, ...]
```

Burada:

- `1`: Feature modele dahil edilir.
- `0`: Feature modele dahil edilmez.

Optimizasyonun amacı, F1-score değerini artıran feature kombinasyonunu bulmaktır. Çok fazla feature seçilmesini engellemek için küçük bir feature penalty uygulanmıştır.

5.6 Optimize Model Eğitimi

`train_optimized_model` task'ı, Cuckoo Search tarafından seçilen feature'ları kullanarak yeni bir Random Forest modeli eğitmiştir.

5.7 Churn Tahminlerinin Üretilmesi

`generate_churn_predictions` task'ı, optimize modeli kullanarak tüm müşteriler için churn tahmini ve churn olasılığı üretmiştir. Ayrıca müşteriler `low`, `medium` ve `high` risk segmentlerine ayrılmıştır.

6. Model Performans Karşılaştırması

Model	Accuracy	Precision	Recall	F1-score	ROC-AUC	Feature Count
Baseline Random Forest	0.789	0.632	0.492	0.553	0.818	30
Cuckoo Optimized Random Forest	0.746	0.516	**0.684**	**0.589**	0.792	**12**

7. Sonuçların Yorumu

Baseline model 30 feature kullanarak 0.553 F1-score ve 0.492 recall üretmiştir. Cuckoo Search ile optimize edilen model ise yalnızca 12 feature kullanarak 0.589 F1-score ve 0.684 recall üretmiştir.

Bu sonuç, Cuckoo Search ile yapılan feature selection işleminin özellikle **recall** açısından önemli bir iyileşme sağladığını göstermektedir.

> **İş Yorumu:** Churn problemlerinde recall kritik bir metriktir çünkü amaç, ayrılma riski taşıyan müşterileri mümkün olduğunca kaçırmamaktır. Optimize model daha fazla churn müşterisini yakalayabildiği için müşteri kaybı önleme kampanyalarında daha kullanışlı olabilir.

8. Üretilen Dosyalar

Dosya	Açıklama
`telco_churn_processed.csv`	Temizlenmiş ve modele hazır hale getirilmiş veri seti
`baseline_churn_model.pkl`	Tüm feature'larla eğitilen baseline model
`baseline_metrics.csv`	Baseline model performans metrikleri
`selected_features.csv`	Cuckoo Search tarafından seçilen feature listesi
`cuckoo_feature_selection_metrics.csv`	Cuckoo Search optimizasyon sonuçları
`optimized_churn_model.pkl`	Seçilen feature'larla eğitilen optimize model

`optimized_metrics.csv`	Optimize model performans metrikleri
`model_comparison.csv`	Baseline ve optimize model karşılaştırması
`churn_predictions.csv`	Müşteri bazlı churn tahminleri ve risk segmentleri

9. Prediction Çıktısı

Final modelin ürettiği tahmin dosyasında aşağıdaki kolonlar bulunmaktadır:

Kolon	Açıklama
`customer_row_id`	Müşteri satır ID'si
`churn_prediction`	1 = churn riski var, 0 = churn riski yok
`churn_probability`	Modelin hesapladığı churn olasılığı
`risk_segment`	low, medium veya high risk segmenti

Örnek Prediction Çıktısı

```
customer_row_id,churn_prediction,churn_probability,risk_segment
1,1,0.753,high
2,0,0.013,low
3,1,0.887,high
4,0,0.000,low
5,1,0.900,high
```

10. Projenin Güçlü Yanları

- Uçtan uca çalışan bir ML pipeline oluşturulmuştur.
- Airflow ile task bazlı, izlenebilir ve tekrar çalıştırılabilir yapı kurulmuştur.
- Cuckoo Search algoritması gerçek bir ML optimizasyon problemine uygulanmıştır.
- Baseline ve optimize model performansları karşılaştırılmıştır.
- Feature sayısı 30'dan 12'ye düşürülürken F1-score ve recall artırılmıştır.
- Final tahmin çıktısı iş birimlerinin anlayabileceği risk segmentlerine dönüştürülmüştür.

11. Geliştirme Fikirleri

- Model tuning için Cuckoo Search algoritması hyperparameter optimization amacıyla da kullanılabilir.
- MLflow eklenerek model versiyonlama yapılabilir.
- Power BI dashboard ile churn risk segmentleri görselleştirilebilir.

- Gerçek zamanlı veya periyodik yeni müşteri verisi geldiğinde DAG schedule ile çalıştırılabilir.
- SHAP analizi ile model açıklanabilirliği artırılabilir.
- Riskli müşteriler için kampanya öneri sistemi eklenebilir.